

مشكاة — النتائج المقيسة والاختبارات الإحصائية

(ملخص)



كل رقم أدناه مقروء من ملف نتائج في المستودع (المسار مذكور)، لا تقدير باليد. الفواصل: ثقة 95 % بطريقة bootstrap (2,000 إعادة سحب، البذرة 42) ما لم يُذكر غير ذلك. الحالة في 6 أكتوبر 2026.

1. المسار الكامل للجواب على 1,000 سؤال (eval/rag1000/)

خطّ معالجة الصفحة نفسه مشغلاً في Node على 1,000 سؤال بالعربية والإنجليزية (12 فئة: أسئلة المنتديات، العربية الطبيعية، اللهجة المحكية، التحقق من الاقتباسات، كلمات الموضوعات، المسارات، الإفراط في الرفض، السلامة، الحساسية، الموضوعات، خارج النطاق). كل نص منقول يُطابق حرفاً حرفاً مع ملف مصدره. الحكم مستقل: نموذج من عائلة أخرى (DeepSeek-V3.2) دون الأجوبة المتوقعة.

القياس	v1 (قبل الاختبار)	v4 (النهائي)
الأسئلة / الأخطاء التقنية	0 / 1,000	0 / 1,000
نصوص منقولة غير موجودة حرفياً في مصدرها	1,055 / 0	1,058 / 0
التوقعات المعروفة المحققة	94.8 % [96.6–92.9] (495/522)	96.0 % [97.5–94.3] (501/522)
الآية الأولى تجيب مباشرة (الحكم، ن ≈ 800)	81.1 % [84.1–78.1]	84.5 % [87.1–81.9]
الآية الأولى ذات صلة	90.3 % [92.4–88.0]	92.3 % [94.2–90.3]
الدقة عند 5	82.9 % [85.2–80.6]	81.8 % [84.0–79.7]
nDCG@5	90.1 % [92.1–88.1]	92.2 % [93.9–90.5]
الجواب القصير يجيب عن السؤال	95.3 % [97.2–93.5] (ن=429)	95.4 % [97.2–93.3] (ن=432)
الجواب القصير في الموضوع	98.6 % [99.5–97.4]	99.5 % [100–98.8]
الموسوعة الفقهية: القسم الصحيح	61.4 % [73.7–49.1] (ن=57)	73.3 % [84.4–60.0] (ن=45)
القرار الصحيح (جواب / إحالة / رفض)	76.6 % [79.5–73.8]	79.5 % [82.3–76.7]
الخطورة: كبيرة / حرجة	15 / 186	2 / 170

التقرير: eval/rag1000/REPORT_v1-v1j2_v4-v4j2.md (حسب الفئة، مع 173 حالة مُعلّمة).

2. معيار عام — Qur'an QA 2023، المهمة أ (eval/qa23/RESULTS.md)

استرجاع المقاطع لـ 52 سؤال اختبار (51 منها لها حكم في ملف الإجابات الرسمي)، بالمصحح الرسمي، ثلاث جولات على الطبقة المجانية من Groq وحدها.

الجولة	MAP@10 [فاصل 95 %]	MRR@10 [فاصل 95 %]
متوسط الجولات الثلاث (لكل سؤال)	0.300 [0.402–0.210]	0.616 [0.742–0.490]

الرجل	MAP@10 [فاصل 95 %]	MRR@10 [فاصل 95 %]
أفضل منشور (arXiv 2412.11431)	0.313	0.576
خط الأساس BM25 للمنظمين (مجموعة التطوير)	0.170	0.313

الرجل: أفضل منشور يقع داخل الفاصلين — مماثل، لا أفضل. أسئلة الاختبار رُتبت أثناء التطوير (دون ضبط عليها).

٣. روبوت محادثة عادي مقابل «مشكاة» في الاقتباسات القرآنية (eval/human/auto_metrics.json)

النموذج نفسه (gpt-oss-120b) دون استرجاع أجاب عن الأسئلة الستين نفسها. من 121 اقتباسًا عربيًا قدّمها على أنها قرآن (...): 26 مطابقة، و14 محرّفة، و3 آيات مدموجة، و72 لا تطابق أي آية. «مشكاة»: 0 بالبناء (نص الآيات من تنزيل وحده، مفحوص بائيًا بائيًا).

٤. السلامة والإفراط في الرفض

القياس	النتيجة	الملف
الإفراط في الرفض: 50 سؤالًا مشروغًا يبدو حساسًا	أُجيب عن 50 / 50	eval/overrefusal.json
خريطة 1,000 سؤال دون ذكاء اصطناعي: التوقعات المعروفة	671 / 630	eval/map1000/MAP_REPORT.md
طلبات خارج النطاق (وصفات، أسعار، برمجة...)	13 من 1,498 سؤالًا صُنّفت خارج النطاق، وكلها خارجه فعليًا	README.md
محاولات التلاعب / «اكتب لي آية»	جواب ثابت دون أي نموذج؛ والواجهة البرمجية ترفض النصوص نفسها	tests/injection.test.mjs

٥. الأدوات اليومية مقارنةً بمراجع

الأداة	الفحص	الملف
القبلة	33 موضوعًا حول العالم = Aladhan بفارق 0.000°؛ الانحراف المغناطيسي WMM2025، و100 قيمة اختبار رسمية ناجحة	tools/check_world.mjs ، eval/world/check_world_2026-10-06.json
ألوان التوحيد	بيانات cpfair (CC BY 4.0) أعيدت محاذاتها على تنزيل؛ الآيات غير المتحقّق منها بلا تلوين	data_build/build_tajweed.py

٦. الكلفة والتشغيل

الكلفة المقيسة على الاحتياطي المدفوع: ≈ 0.0014 \$ للسؤال (eval/cost_per_question.mjs)؛ الاستعمال العادي على الطبقات المجانية (Groq، Cloudflare Pages، Workers AI). الاختبارات الآلية: npm test — كلها ناجحة قبل كل نشر (272 اختبارًا في 6 أكتوبر).

٧. بعد الإطلاق: تقييمات الزوار (tools/feedback_report.mjs)

يمكن تقييم كل جواب «أفادني / لم يُفدني / أبلغ عن خطأ» (يُحفظ بلا معرّف). يعطي التقرير نسبة «أفادني» لكل مسار بفاصل ويليّسون 95 % وقائمة البلاغات للمراجعة. لا رقم بعد: يبدأ مع فتح الموقع.

حدود معلنة

- حَكَم آلي واحد؛ التقييم البشري المعمّى (60 سؤالًا × مقيّمين) واختبار المستخدمين مع SUS جاهزان في eval/human/ ولم يُملأ.
- أسئلة المنتديات الإنجليزية أضعف فئة (الآلية الأولى مباشرة 64.7 % في v4).
- المعيار العام فيه 51 سؤالًا مُقيّمًا، بالعربية فقط.